

Практическое занятие №5: Визуализация данных с Matplotlib и Seaborn

Цель занятия

Освоить основные приёмы визуализации данных с использованием библиотек Matplotlib и Seaborn. Научиться выбирать подходящий тип графика для разных задач анализа, строить и настраивать графики, интерпретировать полученные результаты.

Задачи

1. Изучить возможности библиотек Matplotlib и Seaborn.
2. Научиться строить основные типы графиков: линейные, гистограммы, ящики с усами, scatter plot, тепловые карты, pairplot, bar plot, violin plot.
3. Освоить настройку внешнего вида графиков: размер, подписи, легенда, цветовые палитры.
4. Применить визуализацию для разведочного анализа данных (EDA) на реальных датасетах.
5. Создать комплексный отчёт с графиками по выбранному датасету.

Теоретические основы

1. Роль визуализации в анализе данных

Визуализация позволяет:

- быстро обнаружить закономерности и аномалии;
- понять распределение переменных;
- выявить взаимосвязи между признаками;
- представить результаты анализа в наглядной форме.

2. Обзор библиотек

Matplotlib

- Низкоуровневая библиотека, дающая полный контроль над графиком.
- Позволяет создавать любые типы графиков.
- Основной объект: `Figure` (полотно) и `Axes` (оси).

Seaborn

- Надстройка над Matplotlib, упрощающая создание статистических графиков.

- Красивые темы по умолчанию.
- Интеграция с pandas DataFrame.
- Высокоуровневые функции для сложных графиков (pairplot, heatmap, violinplot).

3. Типы графиков и их применение

Тип графика	Назначение	Примеры применения
Линейный график (line plot)	Отображение изменения величины во времени или по порядку	Динамика продаж, временные ряды, тренды
Гистограмма (histogram)	Распределение одной непрерывной переменной	Распределение возраста, доходов, цен
Ящик с усами (boxplot)	Сравнение распределений категориальных групп, обнаружение выбросов	Распределение зарплат по отделам, анализ выбросов
Столбчатая диаграмма (bar plot)	Сравнение значений по категориям	Продажи по товарам, средние показатели по группам
Точечная диаграмма (scatter plot)	Взаимосвязь двух непрерывных переменных	Зависимость цены от площади, корреляция признаков
Тепловая карта (heatmap)	Визуализация матрицы корреляций или табличных данных	Корреляционная матрица, матрица ошибок классификации
Парные графики (pairplot)	Многомерное исследование взаимосвязей	Быстрый обзор всех попарных отношений в наборе признаков
Скрипичный график (violin plot)	Распределение с ядерной оценкой плотности, сравнение групп	Более информативная альтернатива boxplot
Счётный график (countplot)	Частота категориальных значений	Количество пассажиров по классам, распределение по полу

4. Основные команды и настройки

```
import matplotlib.pyplot as plt
import seaborn as sns

# Установка стиля seaborn
sns.set_style("whitegrid")
sns.set_palette("deep")

# Создание фигуры и осей
fig, ax = plt.subplots(figsize=(10, 6))

# Построение графика (пример)
sns.histplot(data=df, x='age', bins=30, ax=ax)
ax.set_title('Распределение возраста')
```

```
ax.set_xlabel('Возраст')
ax.set_ylabel('Частота')

# Показать график
plt.tight_layout()
plt.show()
```

Подробные примеры с кодом

Пример 1: Анализ выживаемости на Титанике (Seaborn)

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Загрузка данных
df = sns.load_dataset('titanic')

# 1. Счётный график по классу и выживаемости
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

sns.countplot(data=df, x='class', ax=axes[0])
axes[0].set_title('Количество пассажиров по классам')

sns.countplot(data=df, x='class', hue='survived', ax=axes[1])
axes[1].set_title('Выживаемость по классам')

plt.tight_layout()
plt.show()

# 2. Распределение возраста с разбивкой по полу
plt.figure(figsize=(10, 6))
sns.histplot(data=df, x='age', hue='sex', kde=True, bins=30)
plt.title('Распределение возраста по полу')
plt.show()

# 3. Ящик с усами для возраста по классам
plt.figure(figsize=(10, 6))
sns.boxplot(data=df, x='class', y='age', hue='survived')
plt.title('Возраст пассажиров по классам и выживаемости')
plt.show()

# 4. Тепловая карта корреляций числовых признаков
numeric_df = df.select_dtypes(include=['number'])
corr = numeric_df.corr()
plt.figure(figsize=(8, 6))
sns.heatmap(corr, annot=True, cmap='coolwarm', fmt='.2f',
            linewidths=0.5)
plt.title('Корреляционная матрица')
plt.show()
```

Пример 2: Анализ чаевых в ресторане (Scatter plot, violin plot)

```
df = sns.load_dataset('tips')

# 1. Зависимость чаевых от суммы счёта с разделением по времени
дня
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='total_bill', y='tip', hue='time',
style='sex', s=100)
plt.title('Зависимость чаевых от суммы счета')
plt.show()

# 2. Скрипичный график для чаевых по дням недели
plt.figure(figsize=(10, 6))
sns.violinplot(data=df, x='day', y='tip', hue='sex', split=True)
plt.title('Распределение чаевых по дням недели и полу')
plt.show()
```

Пример 3: Временной ряд (линейный график)

```
# Загрузка данных о пассажирах авиалиний
df = sns.load_dataset('flights')

# Преобразование месяца в число
month_map = {'Jan':1, 'Feb':2, 'Mar':3, 'Apr':4, 'May':5,
'Jun':6,
'Jul':7, 'Aug':8, 'Sep':9, 'Oct':10, 'Nov':11,
'Dec':12}
df['month_num'] = df['month'].map(month_map)
df['date'] = pd.to_datetime(df[['year',
'month_num']].assign(day=1))

# Линейный график
plt.figure(figsize=(12, 5))
sns.lineplot(data=df, x='date', y='passengers')
plt.title('Динамика пассажиропотока')
plt.xlabel('Дата')
plt.ylabel('Количество пассажиров')
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

Варианты для самостоятельного выполнения (10 вариантов)

Каждый вариант содержит датасет из библиотеки seaborn (или встроенный в pandas) и перечень заданий на построение графиков. Студент должен загрузить данные, выполнить необходимую предобработку (если требуется) и построить все указанные графики, снабдив их заголовками, подписями и краткими выводами.

Вариант 1: Iris (цветки ириса)

- **Датасет:** `sns.load_dataset('iris')`
- **Задачи:**
 1. Построить гистограммы распределения длины лепестка для каждого вида (три графика на одной фигуре).
 2. Построить ящики с усами для длины чашелистика по видам.
 3. Построить scatter plot зависимости длины лепестка от ширины лепестка, раскрасив точки по виду.
 4. Построить pairplot для всех числовых признаков, раскрасив по виду.

Вариант 2: Tips (чаевые)

- **Датасет:** `sns.load_dataset('tips')`
- **Задачи:**
 1. Построить столбчатую диаграмму средних чаевых по дням недели.
 2. Построить ящики с усами для процента чаевых ($\text{tip}/\text{total_bill} \cdot 100$) по дням недели.
 3. Построить scatter plot зависимости чаевых от суммы счёта с разделением по полу.
 4. Построить тепловую карту корреляции числовых признаков.

Вариант 3: Titanic (Титаник)

- **Датасет:** `sns.load_dataset('titanic')`
- **Задачи:**
 1. Построить countplot для класса пассажиров.
 2. Построить гистограмму возраста с KDE, раскрашенную по полу.
 3. Построить boxplot возраста по классам и выживаемости.
 4. Построить тепловую карту корреляции для числовых признаков (survived, pclass, age, sibsp, parch, fare).

Вариант 4: Flights (пассажиры авиалиний)

- **Датасет:** `sns.load_dataset('flights')`
- **Задачи:**
 1. Построить линейный график динамики пассажиров по годам (среднее за год).
 2. Построить тепловую карту: годы по строкам, месяцы по столбцам, значение – количество пассажиров.
 3. Построить столбчатую диаграмму среднего количества пассажиров по месяцам.
 4. Построить boxplot распределения пассажиров по годам.

Вариант 5: Diamonds (алмазы)

- **Датасет:** `sns.load_dataset('diamonds')`
- **Задачи:**
 1. Построить гистограмму распределения цены.
 2. Построить scatter plot зависимости цены от карата, раскрасив по огранке (cut).
 3. Построить boxplot цены по огранке.
 4. Построить heatmap корреляции для числовых признаков (carat, depth, table, price, x, y, z).

Вариант 6: Penguins (пингвины)

- **Датасет:** `sns.load_dataset('penguins')`
- **Задачи:**
 1. Построить countplot по видам пингвинов.
 2. Построить violinplot длины клюва (bill_length_mm) по видам и острову.
 3. Построить scatter plot длины клюва против длины ласт (flipper_length_mm), раскрасив по виду.
 4. Построить pairplot для числовых признаков, раскрасив по виду.

Вариант 7: MPG (расход топлива)

- **Датасет:** `sns.load_dataset('mpg')`
- **Задачи:**
 1. Построить гистограмму расхода топлива (mpg).
 2. Построить scatter plot зависимости расхода от мощности (horsepower), раскрасив по количеству цилиндров.
 3. Построить boxplot расхода по стране происхождения (origin).
 4. Построить тепловую карту корреляции для числовых признаков.

Вариант 8: Exercise (физические упражнения)

- **Датасет:** `sns.load_dataset('exercise')`
- **Задачи:**
 1. Построить countplot по типу диеты.
 2. Построить boxplot пульса по типу упражнений.
 3. Построить violinplot пульса по времени (time) и диете.
 4. Построить линейный график среднего пульса по времени для каждой диеты.

Вариант 9: Planets (экзопланеты)

- **Датасет:** `sns.load_dataset('planets')`
- **Задачи:**
 1. Построить countplot по методу обнаружения.
 2. Построить гистограмму логарифма массы (`np.log(mass)`) для планет, открытых методом Radial Velocity.
 3. Построить boxplot массы по методу обнаружения (можно логарифмированную массу).
 4. Построить scatter plot зависимости орбитального периода от массы.

Вариант 10: Attention (время реакции)

- **Датасет:** `sns.load_dataset('attention')`
- **Задачи:**
 1. Построить boxplot времени реакции по типу внимания.
 2. Построить violinplot времени реакции по типу задания.
 3. Построить линейный график среднего времени реакции по решению (solution) для каждого типа внимания.
 4. Построить pairplot для числовых признаков, если они есть.

Рекомендации по выполнению

- Используйте Jupyter Notebook для выполнения работы.
- Каждый график оформляйте в отдельной ячейке с пояснительным текстом (Markdown).
- Старайтесь использовать разные стили и цветовые палитры для лучшего восприятия.
- Не забывайте добавлять заголовки, подписи осей, легенды.
- При интерпретации обращайте внимание на выбросы, кластеры, тренды, различия между группами.

Контрольные вопросы для самопроверки

1. В чём основное различие между Matplotlib и Seaborn?
2. Какую библиотеку и какой тип графика вы выберете для визуализации временного ряда?
3. Для чего используется тепловая карта (heatmap)?
4. Как добавить легенду к графику и изменить её расположение?
5. Какие способы обнаружения выбросов с помощью визуализации вы знаете?
6. Как построить несколько графиков на одной фигуре (subplots)?
7. Что показывает KDE (kernel density estimate) на гистограмме?
8. Как изменить цветовую палитру в seaborn?
9. В каких случаях предпочтительнее использовать violinplot вместо boxplot?
10. Как сохранить график в файл?

Критерии оценивания (100-балльная шкала)

Критерий	Баллы
1. Загрузка данных и первичная предобработка	10
- Правильная загрузка датасета	4
- Проверка структуры, типов, пропусков	3
- Необходимые преобразования (если есть)	3
2. Построение графиков (4 графика)	60
- Каждый график: 15 баллов	
* - Выбор правильного типа графика для поставленной задачи	5
* - Корректное использование данных и настроек (оси, подписи, заголовков)	5
* - Читаемость, эстетика, использование цвета и легенды	5
3. Интерпретация результатов	20
- Краткий вывод по каждому графику (1-2 предложения)	10 (2.5 за график)
- Общий аналитический вывод по датасету	10
4. Оформление и код	10
- Код чистый, с комментариями	5
- Вывод графиков в одном блокноте (Jupyter) с пояснениями в Markdown	5
ИТОГО	100

Шкала перевода баллов в оценку

- 90–100 баллов – отлично
- 75–89 – хорошо
- 60–74 – удовлетворительно
- менее 60 – неудовлетворительно

Дополнительные источники информации и литература

1. Официальная документация Matplotlib: <https://matplotlib.org/stable/contents.html>
2. Официальная документация Seaborn: <https://seaborn.pydata.org/>
3. Книга: Уэс Маккинни «Python для анализа данных», глава 9 (визуализация).
4. Курс «Визуализация данных на Python» на Stepik: <https://stepik.org/course/1231>
5. Галерея примеров Matplotlib: <https://matplotlib.org/stable/gallery/index.html>
6. Галерея примеров Seaborn: <https://seaborn.pydata.org/examples/index.html>